Clasificación de dígitos MNIST con una CNN en PyTorch

Tarea: Construye una red neuronal convolucional (CNN) usando PyTorch para clasificar las imágenes del dataset MNIST.

1. Importación de librerías

Importamos las librerías específicas de **PyTorch** para este notebook:

- `torch`, `torch.nn`, `torch.optim`: núcleo de PyTorch para tensores, capas y optimizadores.
- `torchvision` y `torchvision.transforms`: descarga MNIST y aplica pipelines de preprocesado sobre las imágenes.
- `dataclasses`: para centralizar los hiperparámetros en una clase `Config`
- `DataLoader`, `random_split`: iteración por batches y separación de validación.
- `seaborn`: heatmaps para visualizar activaciones de capas fully connected.

Las librerías de propósito general (`numpy`, `matplotlib`, `sklearn.metrics`) se usan de la misma forma que en el notebook de Scikit-learn.

2. Configuración de parámetros

Configuramos los parámetros necesarios para entrenar nuestro modelo. Esto incluye el número de épocas, la tasa de aprendizaje, el tamaño del lote (batch size) y la semilla aleatoria para reproducibilidad.

[2]:
```python
def set_seed(seed: int = 42):
    random.seed(seed)
    np.random.seed(seed)
    torch.manual_seed(seed)
    torch.cuda.manual_seed_all(seed)
    torch.backends.cudnn.deterministic = True
    torch.backends.cudnn.benchmark = False


@dataclass
class Config:
    seed: int = 42
    batch_size: int = 128
    epochs: int = 25
    lr: float = 1e-3
    weight_decay: float = 0.0
    num_workers: int = 0
    val_split: int = 10_000
    device: str = "cuda" if torch.cuda.is_available() else "cpu"
    patience = 5  # nº de epochs sin mejora antes de parar


cfg = Config()
set_seed(cfg.seed)
print("Device:", cfg.device)
```

```
Device: cuda
```

3. Cálculo de media y desviación estándar de MNIST

A diferencia del notebook de Scikit-learn (donde dividíamos por 255 para llevar los píxeles a [0, 1]), aquí aplicamos una **normalización estadística**: restamos la media del dataset y dividimos por su desviación estándar. Esto centra la distribución alrededor de cero, lo que estabiliza el gradiente y acelera la convergencia.

Calculamos ambas estadísticas sobre el conjunto de entrenamiento antes de construir los dataloaders.

[3]:
```
transform = transforms.ToTensor() # Convierte la imagen PIL a un tensor de PyTorch y normaliza los valores a [0, 1]
dataset = torchvision.datasets.MNIST(root='./data', train=True, download=True,
                                     transform=transform)

loader = torch.utils.data.DataLoader(dataset, batch_size=1024, shuffle=False,
                                     num_workers=cfg.num_workers, pin_memory=(cfg.device=="cuda"))

mean = 0.0
std = 0.0
total_pixels = 0

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

for images, _ in loader:
    images = images.to(device)

    mean += images.sum().item()
    std += (images ** 2).sum().item()
    total_pixels += images.numel()

mean = mean / total_pixels
std = (std / total_pixels - mean ** 2) ** 0.5

print(f"Mean: {mean}")
print(f"Std: {std}")
```

```
Mean: 0.13066047761878188
Std: 0.3081078047389192
```

4. Preparar Dataset y Dataloaders con Transformaciones Tensor y Normalización

Preparamos el dataset y los dataloaders para el entrenamiento y la evaluación del modelo. Aplicamos las transformaciones necesarias para convertir las imágenes a tensores de PyTorch y normalizarlas utilizando la media y desviación estándar calculadas previamente.

[4]:
```
transform = transforms.Compose([
    transforms.ToTensor(), # Convierte la imagen PIL a un tensor de PyTorch y␣
  ↪normaliza los valores a [0, 1]
    transforms.Normalize((mean,), (std,)) # Normaliza a media y desviación␣
  ↪estándar calculadas
                                          # para centrar los datos alrededor de 0
])

train_full = torchvision.datasets.MNIST(root='./data', train=True, download=True,␣
  ↪transform=transform)
test_ds = torchvision.datasets.MNIST(root='./data', train=False, download=True,␣
  ↪transform=transform)

#  train = train + val
val_size = cfg.val_split
train_size = len(train_full) - val_size
train_ds, val_ds = random_split(
    train_full,
    [train_size, val_size],
    generator=torch.Generator().manual_seed(cfg.seed)
)

train_loader = DataLoader(train_ds, batch_size=cfg.batch_size, shuffle=True,
                          num_workers=cfg.num_workers, pin_memory=(cfg.
  ↪device=="cuda"))
val_loader   = DataLoader(val_ds, batch_size=cfg.batch_size, shuffle=False,
                          num_workers=cfg.num_workers, pin_memory=(cfg.
  ↪device=="cuda"))
test_loader  = DataLoader(test_ds, batch_size=cfg.batch_size, shuffle=False,
                          num_workers=cfg.num_workers, pin_memory=(cfg.
  ↪device=="cuda"))

print(f"Train: {len(train_ds)} | Val: {len(val_ds)} | Test: {len(test_ds)}")
```

```
Train: 50000 | Val: 10000 | Test: 10000
```

5. Definición de la arquitectura CNN

A diferencia del MLP de Scikit-learn, que aplana directamente los 784 píxeles en un vector, una **CNN** aprovecha la estructura espacial de la imagen: las capas convolucionales detectan patrones locales (bordes, curvas) que se combinan progresivamente en representaciones más abstractas.

Nuestra arquitectura sigue el patrón clásico: dos bloques **Conv –> ReLU –> MaxPool** para extracción de características, seguidos de capas **fully connected** para la clasificación final.

[5]:
```
class CNN_MNIST(nn.Module):
    """
    CNN sencilla y efectiva para MNIST.
```

```
    Estructura:
        - Conv2d(1, 16, kernel_size=3, padding=1) -> ReLU -> MaxPool2d(2, 2)
        - Conv2d(16, 32, kernel_size=3, padding=1) -> ReLU -> MaxPool2d(2, 2)
        - Flatten -> Linear(32*7*7, 128) -> ReLU -> Linear(128, 10)
    """
    def __init__(self):
        super(CNN_MNIST, self).__init__()
        # Capa Convolucional 1: entrada 1, salida 16, kernel 3x3
        # - Toma la imagen original (28x28) con pixeles en escala de grises (de␣
↪ahí que solo necesitemos 1 canal)
        # extraemos 16 características simples p.ej: bordes, esquinas de la imagen␣
↪original.
        self.conv1 = nn.Conv2d(in_channels=1, out_channels=16, kernel_size=3,␣
↪padding=1)
        # Primera función de activación: ReLu - torna los valores negativos en 0 y␣
↪mantiene los positivos
        self.relu1 = nn.ReLU()
        # Primera capa de pooling: MaxPool con kernel 2x2 y 2 pixeles de␣
↪desplazamiento (stride)
        # - Reduce la dimensión espacial a la mitad (de 28x28 a 14x14)
        self.pool1 = nn.MaxPool2d(kernel_size=2, stride=2)

        # Capa Convolucional 2: entrada 16, salida 32, kernel 3x3
        # - Toma las 16 características extraídas en la capa anterior (14x14)
        # y extrae 32 nuevas características más complejas p.ej: combinaciones de␣
↪bordes, formas, etc.
        self.conv2 = nn.Conv2d(in_channels=16, out_channels=32, kernel_size=3,␣
↪padding=1)
        # Segunda ReLu - torna los valores negativos en 0 y mantiene los positivos
        self.relu2 = nn.ReLU()
        # Segunda capa de pooling
        # - Reduce la dimensión espacial a la mitad (de 14x14 a 7x7)
        self.pool2 = nn.MaxPool2d(kernel_size=2, stride=2)

        # Capa lineal (Totalmente conectada)
        # Con 128 neuronas ocultas
        # La imagen original es 28x28. Tras dos maxpools de 2x2, queda de 7x7, y␣
↪con 32 canales (características)
        # en la última capa convolucional
        self.fc1 = nn.Linear(32 * 7 * 7, 128)
        self.relu3 = nn.ReLU()
        # Con 128 neuronas ocultas y 10 neuronas de salida (para las 10 clases de␣
↪dígitos)
        self.fc2 = nn.Linear(128, 10) # 10 clases de salida (dígitos 0-9)

    def forward(self, x):
```

```
        x = self.pool1(self.relu1(self.conv1(x)))
        x = self.pool2(self.relu2(self.conv2(x)))
        x = x.view(x.size(0), -1) # Aplanar la salida convolucional,
        # ya que la capa lineal espera un vector de características en lugar de una imagen 2D.
        x = self.relu3(self.fc1(x))
        x = self.fc2(x)
        return x
```

Imprimimos la arquitectura del modelo para verificar las dimensiones de cada capa.

[6]:
```
model = CNN_MNIST()
model = model.to(cfg.device)
print(model)
```

```
CNN_MNIST(
  (conv1): Conv2d(1, 16, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (relu1): ReLU()
  (pool1): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
  (conv2): Conv2d(16, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (relu2): ReLU()
  (pool2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
  (fc1): Linear(in_features=1568, out_features=128, bias=True)
  (relu3): ReLU()
  (fc2): Linear(in_features=128, out_features=10, bias=True)
)
```

6. Función de pérdida y optimizador

Función de pérdida: CrossEntropyLoss

`nn.CrossEntropyLoss` combina internamente **softmax** (convierte los logits en probabilidades que suman 1) y **entropía cruzada** (penaliza cuanto menor sea la probabilidad asignada a la clase correcta). Es la función de pérdida estándar para clasificación multiclase en PyTorch, equivalente a lo que Scikit-learn aplica internamente en `MLPClassifier`.

[7]:
```
criterion = nn.CrossEntropyLoss()
```

Optimizador: Adam con scheduler

Usamos **Adam** (`lr=1e-3`, `weight_decay=0`) igual que en el notebook de Scikit-learn.

[8]:
```
optimizer = optim.Adam(model.parameters(),
                       lr=cfg.lr, # = 1e-3
                       weight_decay=cfg.weight_decay # = 0
                      )
```

-“lr” (learning rate) es un multiplicador que indica qué tanto variarán los pesos al ajustarse en cada paso

-“weight_decay” es un término de regularización que penaliza los pesos grandes, añadiendo un coste adicional a la función de pérdida. Esto ayuda a evitar el sobreajuste y mejora la capacidad del modelo para generalizar a datos nuevos.

En este caso, weight_decay = 0 implica que no se aplica regularización sobre los pesos del modelo. En este caso, la función de pérdida solo depende del error de predicción, lo que puede facilitar el ajuste a los datos de entrenamiento pero aumentar el riesgo de sobreajuste, ya que no se penalizan los pesos grandes.

Como mejora adicional, añadimos **`ReduceLROnPlateau`**: si `val_acc` no mejora durante 2 epochs consecutivos, el learning rate se reduce a la mitad (`factor=0.5`). Esto permite afinar los pesos una vez que los gradientes son pequeños y un paso grande podría saltarse el mínimo.

[9]:
```
# Extra: Scheduler - Si en una epoch no mejora el val_acc, reduce el lr

scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(
    optimizer,
    mode='max',      # queremos maximizar val_acc
    factor=0.5,      # nuevo_lr = lr * factor
    patience=2       # espera 2 epochs antes de reducir
)
```

“mode” determina la medida usada para el early stopping. En este caso, ‘max’ significa que se quiere maximizar la metrica val_acc.

“factor” es el factor por el cual se reduce el learning rate. En este caso, se reduce la tasa de aprendizaje en un 50%.

“patience” es la cantidad de epochs que tienen que pasar antes de que se aplique la reduccion

7. Entrenamiento

[10]:
```
def accuracy_from_logits(logits: torch.Tensor, y: torch.Tensor) -> float:
    preds = logits.argmax(dim=1)
    return (preds == y).float().mean().item()


@torch.no_grad() # no se necesita gradiente para la evaluación
def evaluate(model: nn.Module, loader: DataLoader, device: str, preds_labels:␣
 ↪bool = False):

    total_loss = 0.0
    total_acc = 0.0
    n_batches = 0
    all_preds = []
    all_labels = []
```

```
    for images, labels in loader:
        images = images.to(device, non_blocking=True)
        labels = labels.to(device, non_blocking=True)

        logits = model(images)
        loss = criterion(logits, labels)

        total_loss += loss.item()
        total_acc += accuracy_from_logits(logits, labels)

        if preds_labels:
            _, predicted = torch.max(logits, 1)
            all_preds.extend(predicted.cpu().numpy())
            all_labels.extend(labels.cpu().numpy())
        n_batches += 1

    return total_loss / n_batches, total_acc / n_batches, all_preds, all_labels


def train_one_epoch(model: nn.Module, loader: DataLoader, optimizer: torch.optim.
 ↪Optimizer, device: str):
    total_loss = 0.0
    total_acc = 0.0
    n_batches = 0

    for images, labels in loader:
        images = images.to(device, non_blocking=True) # mover a la GPU
        labels = labels.to(device, non_blocking=True) # non_blocking: no bloquear␣
 ↪el hilo

        optimizer.zero_grad(set_to_none=True) # limpiar gradiente: 0 = None
        logits = model(images) # El modelo toma un batch de imágenes y produce un␣
 ↪batch de predicciones (logits)
        loss = criterion(logits, labels)
        loss.backward()
        optimizer.step()

        total_loss += loss.item()
        total_acc += accuracy_from_logits(logits, labels)
        n_batches += 1

    return total_loss / n_batches, total_acc / n_batches
```

A diferencia del notebook de Scikit-learn (donde Scikit-learn abstrae todo en `.fit()`) o Keras (`model.fit`), en PyTorch controlamos explícitamente cada paso del bucle: forward pass, cálculo de pérdida, backward pass y actualización de pesos.

Incluimos **early stopping** (detener si `val_acc` no mejora en 5 epochs consecutivos) y guardamos

el mejor checkpoint del modelo según `val_acc`.

[11]:
```python
best_path = "best_mnist_model.pt"
epochs_without_improve = 0
best_val_acc = 0.0

for epoch in range(1, cfg.epochs + 1):
    # Entrenamiento
    model.train()
    train_loss, train_acc = train_one_epoch(model, train_loader, optimizer, cfg.
 ↪device)

    # Validación
    model.eval()
    val_loss, val_acc, _, _  = evaluate(model, val_loader, cfg.device)


    print(
        f"Epoch {epoch:02d}/{cfg.epochs} | "
        f"Train loss: {train_loss:.4f} Train Acc: {train_acc:.4f} | "
        f"Val loss: {val_loss:.4f} Val Acc: {val_acc:.4f}"
    )

    scheduler.step(val_acc) # reduce lr si no hay mejora en val_acc

    # Guardar mejor modelo por val_acc
    if val_acc > best_val_acc:
        best_val_acc = val_acc
        epochs_without_improve = 0
        torch.save({
            "model_state_dict": model.state_dict(),
            "config": cfg.__dict__,
            "val_acc": best_val_acc
        }, best_path)
    else:
        epochs_without_improve += 1

    if epochs_without_improve >= cfg.patience:
        print("Early stopping activado")
        break

print("Mejor val_acc:", best_val_acc)
print("Guardado en:", best_path)
```

```
Epoch 01/25 | Train loss: 0.2504 Train Acc: 0.9270 | Val loss: 0.0944 Val Acc:
0.9729

Epoch 02/25 | Train loss: 0.0676 Train Acc: 0.9795 | Val loss: 0.0658 Val Acc:
0.9786
```

```
Epoch 03/25 | Train loss: 0.0467 Train Acc: 0.9857 | Val loss: 0.0493 Val Acc:
0.9848

Epoch 04/25 | Train loss: 0.0340 Train Acc: 0.9894 | Val loss: 0.0469 Val Acc:
0.9864

Epoch 05/25 | Train loss: 0.0275 Train Acc: 0.9910 | Val loss: 0.0496 Val Acc:
0.9852

Epoch 06/25 | Train loss: 0.0214 Train Acc: 0.9934 | Val loss: 0.0448 Val Acc:
0.9879

Epoch 07/25 | Train loss: 0.0173 Train Acc: 0.9945 | Val loss: 0.0428 Val Acc:
0.9874

Epoch 08/25 | Train loss: 0.0147 Train Acc: 0.9955 | Val loss: 0.0516 Val Acc:
0.9857

Epoch 09/25 | Train loss: 0.0117 Train Acc: 0.9961 | Val loss: 0.0398 Val Acc:
0.9883

Epoch 10/25 | Train loss: 0.0107 Train Acc: 0.9965 | Val loss: 0.0858 Val Acc:
0.9774

Epoch 11/25 | Train loss: 0.0086 Train Acc: 0.9974 | Val loss: 0.0549 Val Acc:
0.9866

Epoch 12/25 | Train loss: 0.0087 Train Acc: 0.9970 | Val loss: 0.0501 Val Acc:
0.9890

Epoch 13/25 | Train loss: 0.0071 Train Acc: 0.9975 | Val loss: 0.0526 Val Acc:
0.9874

Epoch 14/25 | Train loss: 0.0055 Train Acc: 0.9981 | Val loss: 0.0512 Val Acc:
0.9871

Epoch 15/25 | Train loss: 0.0073 Train Acc: 0.9974 | Val loss: 0.0515 Val Acc:
0.9885

Epoch 16/25 | Train loss: 0.0019 Train Acc: 0.9994 | Val loss: 0.0458 Val Acc:
0.9910

Epoch 17/25 | Train loss: 0.0005 Train Acc: 0.9999 | Val loss: 0.0464 Val Acc:
0.9905

Epoch 18/25 | Train loss: 0.0002 Train Acc: 1.0000 | Val loss: 0.0482 Val Acc:
0.9909

Epoch 19/25 | Train loss: 0.0002 Train Acc: 1.0000 | Val loss: 0.0496 Val Acc:
0.9911

Epoch 20/25 | Train loss: 0.0001 Train Acc: 1.0000 | Val loss: 0.0498 Val Acc:
0.9905

Epoch 21/25 | Train loss: 0.0001 Train Acc: 1.0000 | Val loss: 0.0506 Val Acc:
0.9908
```

```
Epoch 22/25 | Train loss: 0.0001 Train Acc: 1.0000 | Val loss: 0.0511 Val Acc:
0.9905

Epoch 23/25 | Train loss: 0.0001 Train Acc: 1.0000 | Val loss: 0.0517 Val Acc:
0.9907

Epoch 24/25 | Train loss: 0.0001 Train Acc: 1.0000 | Val loss: 0.0521 Val Acc:
0.9907
Early stopping activado
Mejor val_acc: 0.9910996835443038
Guardado en: best_mnist_model.pt
```

8. Evaluación

Evaluamos el modelo sobre el conjunto de test, que no ha intervenido en ningún momento del entrenamiento ni en el criterio de early stopping.

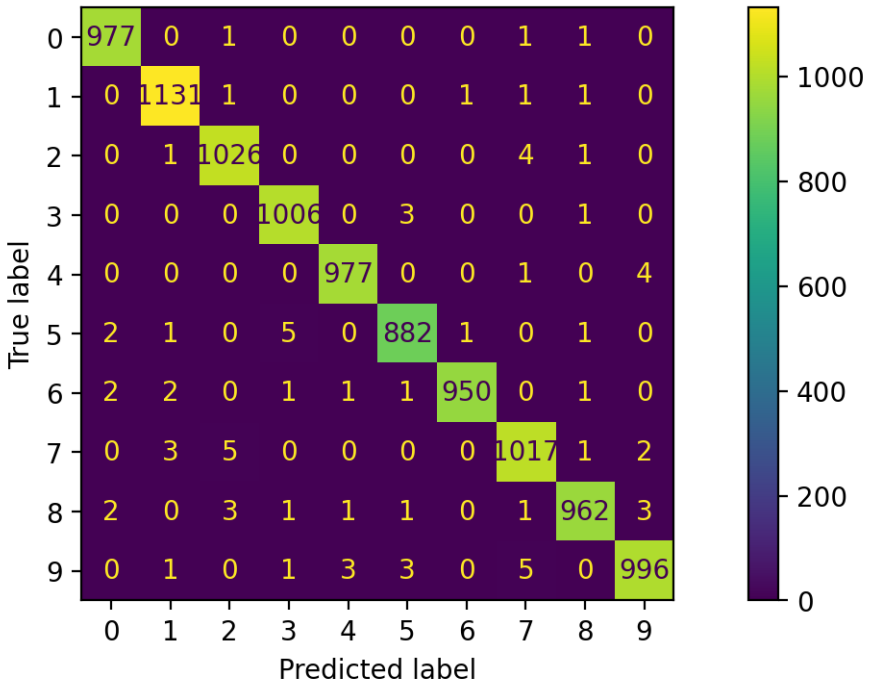
[12]:
```
print("\nEvaluando modelo...")
model.eval()
all_preds = []
all_labels = []
test_loss, test_acc, all_preds, all_labels = evaluate(model, test_loader, cfg.
  ↪device, preds_labels = True)

print(f"\nExactitud (Accuracy): {test_acc * 100:.2f}%")
print(f"Pérdida (Loss): {test_loss * 100:.2f}%")
print("Matriz de Confusión:")
ConfusionMatrixDisplay.from_predictions(all_labels, all_preds)
```

```
Evaluando modelo…

Exactitud (Accuracy): 99.25%
Pérdida (Loss): 3.83%
Matriz de Confusión:
```

[12]:
```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at
0x7cd34dd019d0>
```



La CNN alcanza una accuracy de ~**99.25 %** en el conjunto de prueba, superando claramente el techo del MLP de Scikit-learn (~97.9 %) al aprovechar la estructura espacial de las imágenes.

9. Visualización de características

Inspeccionamos las activaciones intermedias de la CNN para una imagen de test concreta. Esto permite entender qué patrones aprende cada etapa de la red, desde bordes simples en las primeras capas hasta formas abstractas en las últimas.

[13]:
```
__file__ = os.path.abspath("clasificacion_mnist_cnn_pytorch.ipynb")
current_dir = os.path.dirname(__file__)
img_dir = os.path.join(current_dir, "pytorch-mnist-features")

os.makedirs(img_dir, exist_ok=True)

print(img_dir)

def visualizar_caracteristicas(modelo, imagen_tensor):
    modelo.eval()
    imagen_tensor = imagen_tensor.to(cfg.device)

    with torch.no_grad():
        features = modelo.conv1(imagen_tensor.unsqueeze(0))
        plot_caracteristicas(features, title="Características después de Conv1",
            desc="Cada filtro aprende patrones básicos sobre la imagen original:␣
 ↪bordes horizontales, curvas simples, transiciones de intensidad. Los 16 mapas␣
 ↪muestran la respuesta de cada filtro en cada posición de la imagen.")
```

```
        features = modelo.relu1(features)
        plot_caracteristicas(features, title="Características después de ReLU1",
            desc="Se eliminan los valores negativos (se ponen a 0). Desaparecen␣
↪las zonas que no aportan evidencia positiva del patrón que busca cada filtro:␣
↪solo quedan activaciones positivas, lo que aumenta el contraste y centra la␣
↪atención de la red en las zonas relevantes.")

        features = modelo.pool1(features)
        plot_caracteristicas(features, title="Características después de Pool1",
            desc="MaxPooling 2×2: se reduce la resolución de 28×28 a 14×14␣
↪conservando el valor máximo de cada región. Las imágenes son más comprimidas␣
↪pero las zonas más activas se conservan. La red gana invarianza a pequeñas␣
↪traslaciones.")

        features = modelo.conv2(features)
        plot_caracteristicas(features, title="Características después de Conv2",
            desc="Los 32 filtros trabajan ahora sobre features ya procesadas, no␣
↪píxeles crudos. Aprenden combinaciones de patrones básicos: formas curvas,␣
↪bucles, estructuras más abstractas características de cada dígito.")

        features = modelo.relu2(features)
        plot_caracteristicas(features, title="Características después de ReLU2",
            desc="Segunda eliminación de negativos. Las activaciones son más␣
↪definidas y selectivas: solo sobreviven las zonas donde la red detecta con␣
↪confianza los patrones aprendidos en Conv2.")

        features = modelo.pool2(features)
        plot_caracteristicas(features, title="Características después de Pool2",
            desc="Segunda reducción espacial: de 14×14 a 7×7. La red tiene ahora␣
↪una representación compacta: 32 mapas de 7×7 = 1568 valores que capturan los␣
↪patrones más discriminativos para la clasificación.")

        flattened = features.view(features.size(0), -1)
        features = modelo.fc1(flattened)
        plot_fc_features(features, "Activaciones FC1",
            desc="Se pasa de 32 mapas 2D de 7×7 a un vector de 128 neuronas. Ya no␣
↪hay localidad espacial: cada neurona agrega información global de toda la␣
↪imagen combinando todos los patrones detectados.")

        features = modelo.relu3(features)
        plot_fc_features(features, "Activaciones ReLU3",
            desc="Igual que antes: se eliminan los negativos. Más ceros implica␣
↪activaciones más selectivas: solo las combinaciones de patrones que el modelo␣
↪considera relevantes para identificar el dígito permanecen activas.")
```

```
        features = modelo.fc2(features)
        plot_fc_features(features, "Activaciones FC2",
            desc="Capa de salida: las 128 activaciones se comprimen en 10 valores␣
 ↪(logits), uno por dígito. Cuanto más oscuro el color, mayor el score para esa␣
 ↪clase. Tras softmax, estos logits se convierten en probabilidades que suman 1:␣
 ↪la clase con mayor valor es la predicción final.")


def plot_caracteristicas(features, title, desc=""):
    features = features.squeeze(0)  # [canales, H, W]
    num_canales = features.shape[0]

    n_cols = 8
    n_rows = (num_canales + n_cols - 1) // n_cols
    fig, axes = plt.subplots(n_rows, n_cols, figsize=(n_cols*2, n_rows*2))

    axes = axes.flatten()
    for i in range(num_canales):
        ax = axes[i]
        ax.imshow(features[i].cpu().numpy(), cmap='binary')
        ax.axis('off')
        ax.set_title(f"Filtro {i+1}", fontsize=10)

    plt.subplots_adjust(top=0.8, hspace=0.3, wspace=0.1)
    fig.suptitle(title, fontsize=14)
    filename = title.lower().strip().replace(" ", "_") + ".png"
    filepath = os.path.join(img_dir, filename)
    plt.savefig(filepath, dpi=300)
    plt.show()

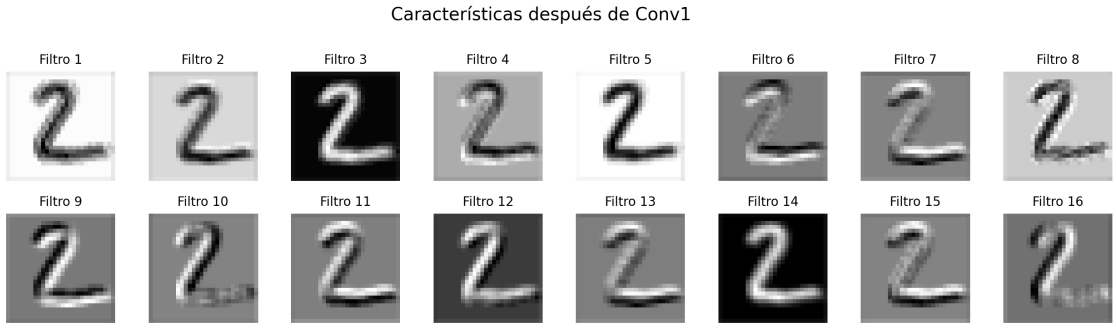
    if desc:
        print(f"\n--> {desc}\n")


def plot_fc_features(features, title, desc=""):
    features = features.squeeze(0).cpu().numpy()
    plt.figure(figsize=(10, 1.7))
    sns.heatmap(features[np.newaxis, :], cmap='binary', cbar=True)
    plt.title(title)
    filename = title.lower().strip().replace(" ", "_") + ".png"
    filepath = os.path.join(img_dir, filename)
    plt.savefig(filepath, dpi=300)
    plt.show()

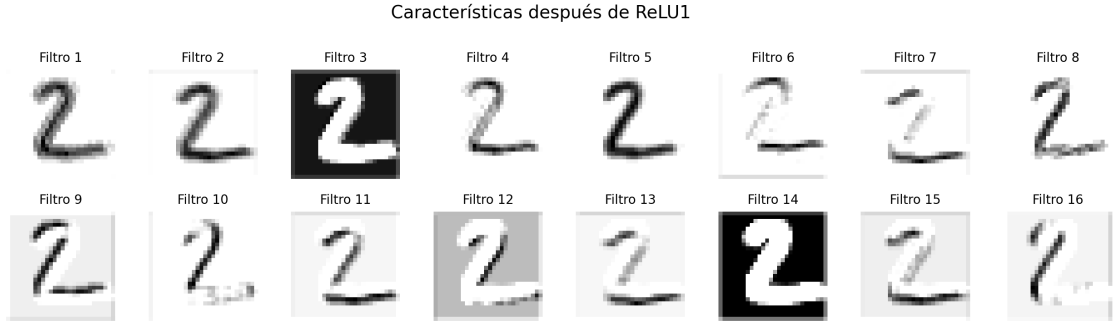
    if desc:
        print(f"\n--> {desc}\n")
```

```
sample_img, _ = test_ds[1]
visualizar_caracteristicas(model, sample_img)
```

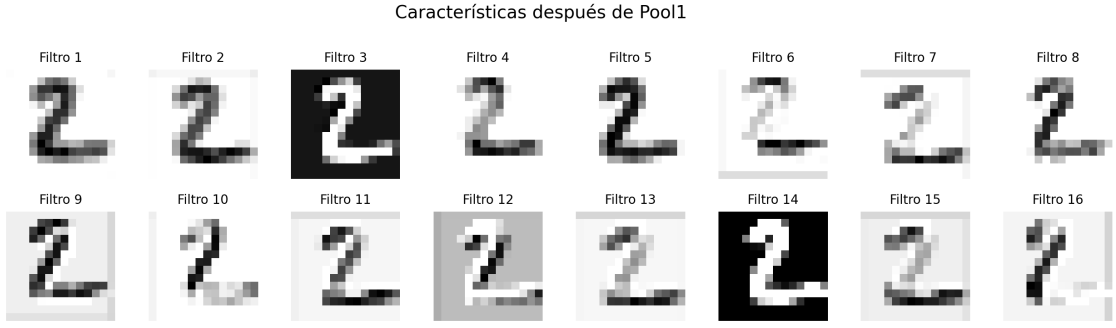
```
/home/eze/IA-BigData/M03_ProgramacionDeIA/RA2/T3/ACT_OBL_03/pytorch-mnist-features
```



--> Cada filtro aprende patrones básicos sobre la imagen original: bordes horizontales, curvas simples, transiciones de intensidad. Los 16 mapas muestran la respuesta de cada filtro en cada posición de la imagen.

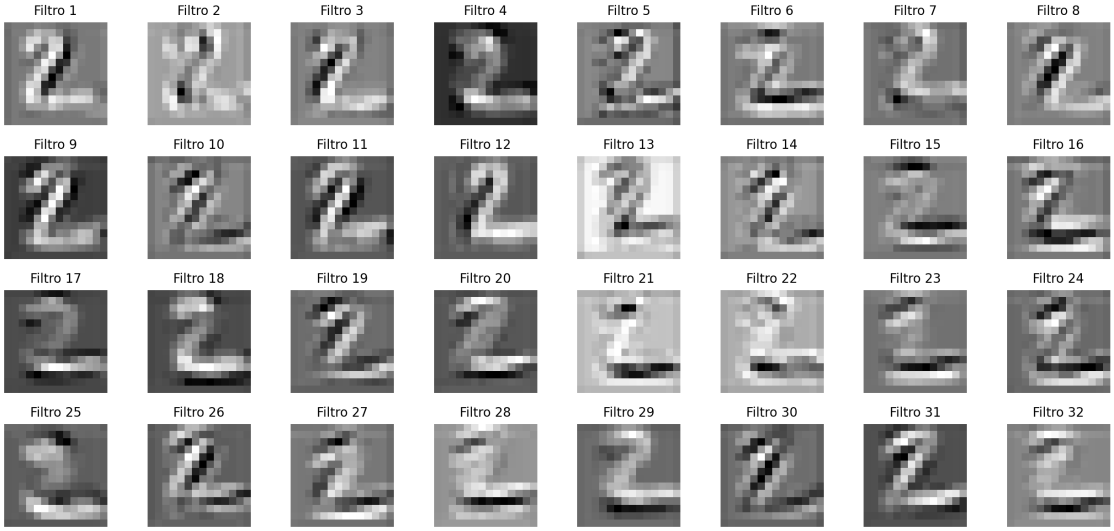


--> Se eliminan los valores negativos (se ponen a 0). Desaparecen las zonas que no aportan evidencia positiva del patrón que busca cada filtro: solo quedan activaciones positivas, lo que aumenta el contraste y centra la atención de la red en las zonas relevantes.



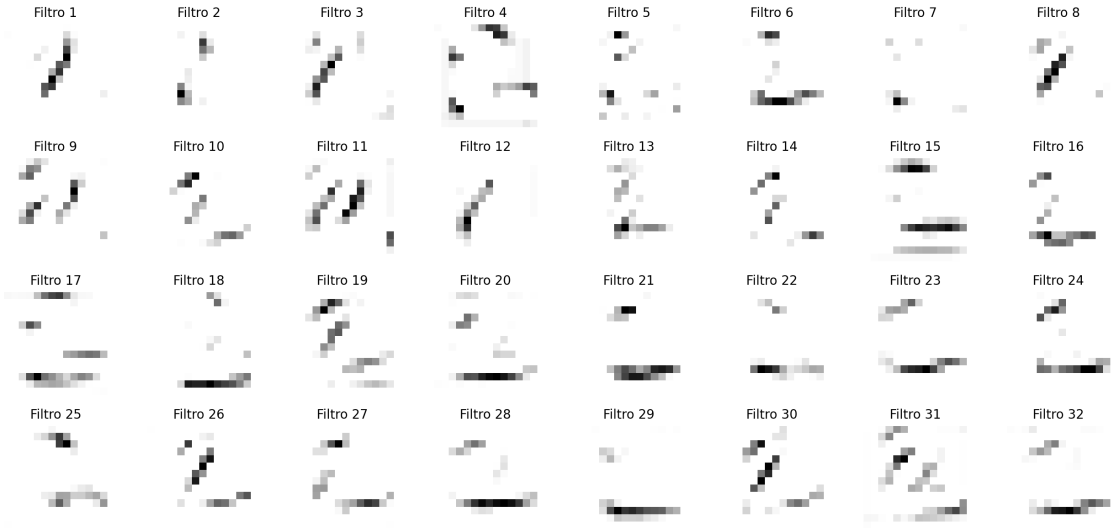
--> MaxPooling 2×2: se reduce la resolución de 28×28 a 14×14 conservando el valor máximo de cada región. Las imágenes son más comprimidas pero las zonas más activas se conservan. La red gana invarianza a pequeñas traslaciones.

Características después de Conv2

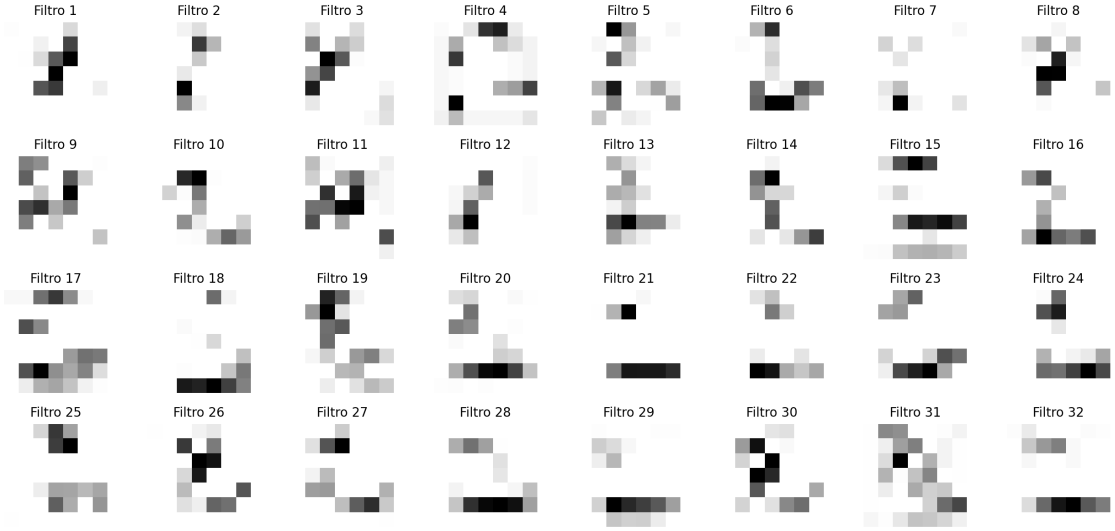


--> Los 32 filtros trabajan ahora sobre features ya procesadas, no píxeles crudos. Aprenden combinaciones de patrones básicos: formas curvas, bucles, estructuras más abstractas características de cada dígito.

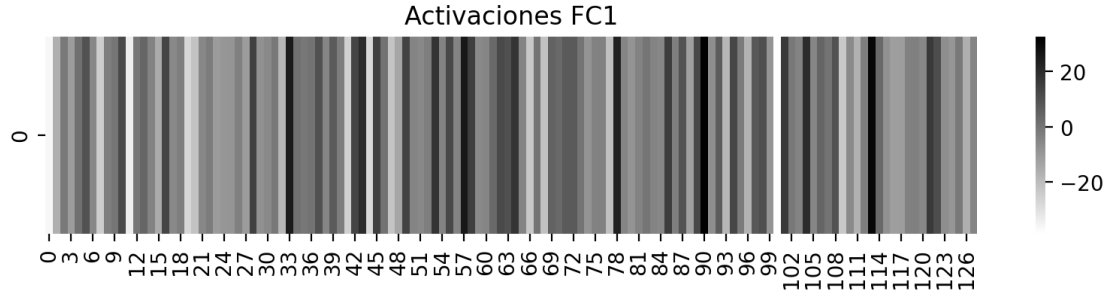
Características después de ReLU2



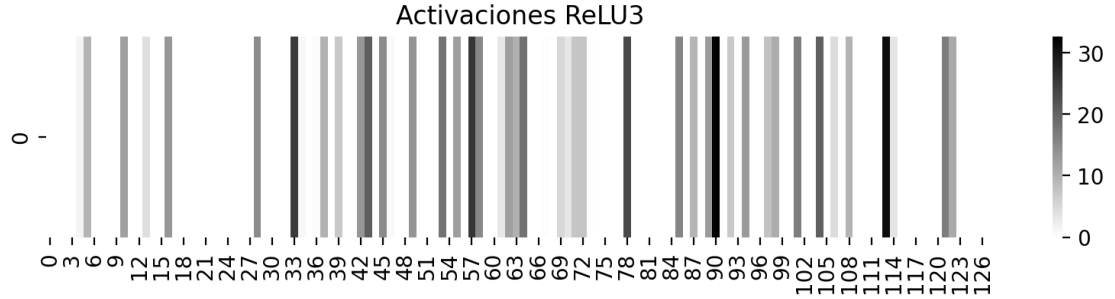
--> Segunda eliminación de negativos. Las activaciones son más definidas y selectivas: solo sobreviven las zonas donde la red detecta con confianza los patrones aprendidos en Conv2.



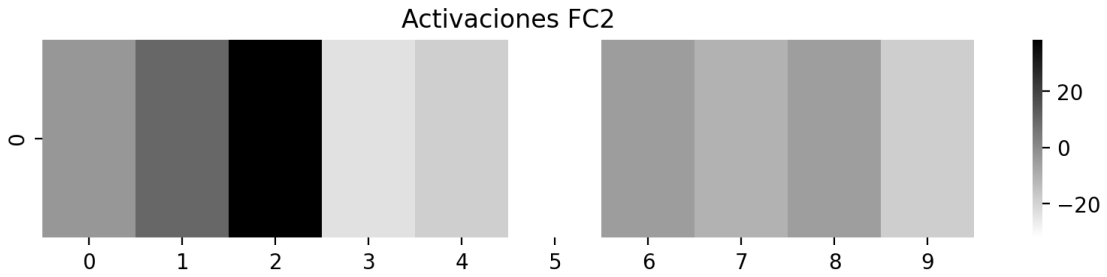
--> Segunda reducción espacial: de 14×14 a 7×7. La red tiene ahora una representación compacta: 32 mapas de 7×7 = 1568 valores que capturan los patrones más discriminativos para la clasificación.



--> Se pasa de 32 mapas 2D de 7×7 a un vector de 128 neuronas. Ya no hay localidad espacial: cada neurona agrega información global de toda la imagen combinando todos los patrones detectados.



--> Igual que antes: se eliminan los negativos. Más ceros implica activaciones más selectivas: solo las combinaciones de patrones que el modelo considera relevantes para identificar el dígito permanecen activas.



`--> Capa de salida: las 128 activaciones se comprimen en 10 valores (logits), uno por dígito. Cuanto más oscuro el color, mayor el score para esa clase. Tras softmax, estos logits se convierten en probabilidades que suman 1: la clase con mayor valor es la predicción final.`

Conclusiones

La CNN de PyTorch alcanza ~99.25% de accuracy, mejorando significativamente el 97.9% del MLP de Scikit-learn. La clave está en las capas convolucionales: en lugar de tratar cada píxel como independiente, aprenden filtros que detectan patrones locales (bordes, curvas) y los combinan jerárquicamente en representaciones cada vez más abstractas, como muestra la visualización de la Sección 9.

PyTorch exige bastante más código que Scikit-learn (bucle de entrenamiento manual, gestión explícita de gradientes y dispositivo, early stopping propio), pero a cambio ofrece control total sobre cada paso, lo que facilita la experimentación y la extensión a arquitecturas más complejas. El scheduler `ReduceLROnPlateau` y el guardado del mejor checkpoint son ejemplos de esa flexibilidad.